Чтение файлов

Глава 7

Пайтон для всех

www.py4e.com

UMSI

CC BY

Пора найти Данные, с которыми можно поработать!

From stephen.marquard@uct.ac.za Sat Jan 5 09:14:16 2008
Return-Path: <postmaster@collab.sakaiproject.org>
Date: Sat, 5 Jan 2008 09:12:18 -0500To: source@collab.sakaiproject.orgFrom: stephen.marquard@uct.ac.zaSubject: [sakai] svn commit: r39772 - content/branches/Details: http://source.sakaiproject.org/viewsvn/?view=rev&rev=39772
...

Работа с файлом

Текстовый файл можно представить как последовательность строк:

```
From stephen.marquard@uct.ac.za Sat Jan  5 09:14:16 2008
Return-Path: <postmaster@collab.sakaiproject.org>
Date: Sat, 5 Jan 2008 09:12:18 -0500
To: source@collab.sakaiproject.org
From: stephen.marquard@uct.ac.za
Subject: [sakai] svn commit: r39772 - content/branches/

Details: http://source.sakaiproject.org/viewsvn/?view=rev&rev=39772
```

http://www.py4e.com/code/mbox-short.txt

Открытие файла

- Прежде чем мы сможем прочитать содержимое файла, нужно сообщить Пайтону, с каким файлом мы собираемся работать и что будем с ним делать
- Функция open() служит для открытия файлов
- Функция open() возвращает «дескриптор файла» — это переменная, используемая для операций с файлом
- Аналогично операции “Файл -> Открыть” в текстовом редакторе

Использование open()

```
fhand = open('mbox.txt', 'r')
```

- handle = open(filename, mode)
- возвращает дескриптор для управления файлом
- имя файла (filename) — это строка
- указание режима (mode) не является обязательным, но он должен быть 'r', если мы собираемся читать файл, и 'w', если собираемся записывать в файл

Что такое дескриптор?

```
>>> fhand = open('mbox.txt')
>>> print(fhand)
<_io.TextIOWrapper name='mbox.txt' mode='r' encoding='UTF-8'>
```

Когда файлы отсутствуют

```
>>> fhand = open('stuff.txt')
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
FileNotFoundError: [Errno 2] No such file or
directory: 'stuff.txt'
```

Данный файл или каталог отсутствует

Символ перевода строки

- Чтобы обозначить конец строки, используется специальный символ —«перевод / разрыв строки»
- В строках пишется \n
- Перевод строки (\n) — это один символ, а не два

```
>>> stuff = 'Привет,\nМир!'
>>> stuff
'Привет,\nМир!'
>>> print(stuff)
Привет,
Мир!
>>> stuff = 'X\nY'
>>> print(stuff)
X
Y
>>> len(stuff)
3
```

Работа с файлом

Текстовый файл можно представить как последовательность строк:

```
From stephen.marquard@uct.ac.za Sat Jan  5 09:14:16 2008
Return-Path: <postmaster@collab.sakaiproject.org>
Date: Sat, 5 Jan 2008 09:12:18 -0500
To: source@collab.sakaiproject.org
From: stephen.marquard@uct.ac.za
Subject: [sakai] svn commit: r39772 - content/branches/

Details: http://source.sakaiproject.org/viewsvn/?view=rev&rev=39772
```

Работа с файлом

Текстовый файл содержит символ перевода строки в конце каждой строки:

```
From stephen.marquard@uct.ac.za Sat Jan  5 09:14:16 2008\n
Return-Path: <postmaster@collab.sakaiproject.org>\n
Date: Sat, 5 Jan 2008 09:12:18 -0500\n
To: source@collab.sakaiproject.org\n
From: stephen.marquard@uct.ac.za\n
Subject: [sakai] svn commit: r39772 - content/branches/\n
\n
Details: http://source.sakaiproject.org/viewsvn/?view=rev&rev=39772\n
```

Чтение файлов в Пайтон

Дескриптор файла как последовательность

- Дескриптор файла, открытый для чтения, можно рассматривать как последовательность строк, где каждая строка файла — строка в последовательности
- Мы можем использовать оператор for, чтобы последовательно перебирать строки
- Помните: последовательность — это упорядоченный набор

```
xfile =
open('mbox.txt')
for cheese in xfile:
    print(cheese)
```

Подсчет строк в файле

- Открываем файл в режиме «только для чтения»
- Используем цикл с for, чтобы прочесть каждую строку
- Подсчитываем строки и выводим количество строк

```
fhand = open('mbox.txt')
count = 0
for line in fhand:
    count = count + 1
print('Всего строк:', count)
```

```
$ python open.py
Всего строк: 132045
```

Чтение файла *целиком*

Мы можем прочитать весь файл (всё содержимое и переводы строк) в одну строку

```
>>> fhand = open('mbox-short.txt')
>>> inp = fhand.read()
>>> print(len(inp))
94626
>>> print(inp[:20])
From stephen.marquar
```

Поиск по файлу

С помощью оператора if внутри цикла for можно выводить только строки, соответствующие определённым критериям

```
fhand = open('mbox-short.txt')
for line in fhand:
    if line.startswith('From:') :
        print(line)
```

Ой!

Что здесь делают все эти пустые строки?

```
From: stephen.marquard@uct.ac.za

From: louis@media.berkeley.edu

From: zqian@umich.edu

From: rjlowe@iupui.edu
...
```

Ой!

Что здесь делают все эти пустые строки?

- В конце каждой строки файла находится символ перевода строки
- Оператор print добавляет символ перевода строки к каждой строке

```
From: stephen.marquard@uct.ac.za\n
\n
From: louis@media.berkeley.edu\n
\n
From: zqian@umich.edu\n
\n
From: rjlowe@iupui.edu\n
\n
...
```

Поиск по файлу (исправленный)

- Мы можем удалить пробелы с правой стороны строки, используя rstrip() из библиотеки работы со строками

- Строка, содержащая символ перевода строки, считается «пустым пространством» и удаляется

```
fhand = open('mbox-short.txt')
for line in fhand:
    line = line.rstrip()
    if line.startswith('From:') :
        print(line)
```

From: stephen.marquard@uct.ac.za
From: louis@media.berkeley.edu
From: zqian@umich.edu
From: rjlowe@iupui.edu
....

Пропуск с использованием continue

Если нужно, мы можем пропустить строку, используя оператор continue

```
fhand = open('mbox-short.txt')
for line in fhand:
    line = line.rstrip()
    if not line.startswith('From:') :
        continue
    print(line)
```

Используем in, чтобы выбрать строки

Мы можем поискать подстроку в (in) любой строке (line), используя соответствующий критерий поиска

```
fhand = open('mbox-short.txt')
for line in fhand:
    line = line.rstrip()
    if not '@uct.ac.za' in line :
        continue
    print(line)
```

```
From stephen.marquard@uct.ac.za Sat Jan  5 09:14:16 2008
X-Authentication-Warning: set sender to stephen.marquard@uct.ac.za using -f
From: stephen.marquard@uct.ac.za
Author: stephen.marquard@uct.ac.za
From david.horwitz@uct.ac.za Fri Jan  4 07:02:32 2008
X-Authentication-Warning: set sender to david.horwitz@uct.ac.za using -f...
```

```
fname = input('Введите имя файла:  ')
fhand = open(fname)
count = 0
for line in fhand:
    if line.startswith('Subject:') :
        count = count + 1
print('Найдено', count, `строк, содержащих subject в',
fname)
```

Запрос имени файла

Введите имя файла: mbox.txt
Найдено 1797 строк, содержащих subject в mbox.txt

Введите имя файла: mbox-short.txt
Найдено 27 строк, содержащих subject в mbox-short.txt

Неверное имя файла

```
fname = input('Введите имя файла:  ')
try:
    fhand = open(fname)
except:
    print('Неверное имя файла:', fname)
    quit()

count = 0
for line in fhand:
    if line.startswith('Subject:') :
        count = count + 1
print(`Найдено', count, `строк, содержащих subject
в', fname)
```

Введите имя файла: mbox.txt
Найдено 1797 строк, содержащих subject в mbox.txt

Введите имя файла: na na boo boo
Неверное имя файла: na na boo boo

Резюме

- Вторичная память
- Открытие файла, дескриптор файла
- Структура файла, символ перевода строки
- Построчное чтение файла с помощью цикла с for
- Поиск строк в файле
- Чтение имен файлов
- Неверное имя файла

Авторы / Благодарности

Авторские права на эти слайды принадлежат Чарльзу Р. Северансу (www.dr-chuck.com) , 2010 г., Школа Информации Мичиганского Университета и доступны по лицензии Creative Commons Attribution 4.0 License. Пожалуйста, сохраняйте этот слайд во всех копиях этого документа, в соответствии с требованиями Лицензии. Если вы внесли изменения, добавьте свое имя или организацию в список участников на этой странице.

Исходная разработка: Чарльз Северанс, Школа Информации Мичиганского Университета.

Перевод выполнила Фомкина Виолетта.

… Добавьте сюда новых авторов и переводчиков

...